



Métodos de Estimação

Professor: Pedro M. Almeida-Junior

24 de fevereiro de 2022

Departamento de Estatística (UEPB)

Métodos de Estimação

- É possível obter muitos estimadores para o mesmo parâmetro a partir de regras de estimação diferentes. Assim, serão abordados a seguir alguns métodos de estimação.
 1. Método da Máxima Verossimilhança
 2. Método dos Momentos

Método da máxima verossimilhança

- Seja X_1, \dots, X_n uma AAS de uma variável aleatória com função de densidade ou de probabilidade $f(x | \theta)$. A função $L(\theta)$, que é

$$L(\theta) = \prod_{i=1}^n f(x_i | \theta)$$

que determina, para cada conjunto de valores observados de X_1, \dots, X_n a probabilidade de se obter estes valores é chamada função de verossimilhança de θ .

- A função de verossimilhança correspondente a uma amostra aleatória observada é definida como sendo igual a função densidade (ou de probabilidade) conjunta, embora seja interpretada diferentemente como função de θ para X_1, \dots, X_n conhecidos.
- Neste caso, um estimador razoável para θ é aquele que maximiza a chance relativa de se obter o que realmente foi observado. Sendo assim, o valor $\hat{\theta}$ e θ , correspondente ao máximo global de $L(\theta)$, se existir é chamado estimador de máxima verossimilhança (EMV) de θ .

- O logaritmo natural da função de verossimilhança de θ é denotado por

$$I(\theta) = \log L(\theta)$$

OBS: O valor que maximiza $L(\theta)$, também maximiza $I(\theta)$, uma vez que o logaritmo é função decrescente.

No caso uniparamétrico onde Θ é um intervalo da reta e $I(\theta; x)$ é derivável, o estimador de máxima verossimilhança pode ser encontrado como a raiz da equação de verossimilhança

$$I'(\theta; x) = \frac{\partial I(\theta; x)}{\partial \theta} \Big|_{\theta=\hat{\theta}} = 0$$

Em alguns exemplos simples, a solução da equação de verossimilhança pode ser **obtida explicitamente**. Em situações mais complicadas, a solução da equação acima será em geral obtida por **procedimentos numéricos**. Para se concluir que a solução da equação anterior é um ponto de máximo, é necessário verificar se

$$I''(\hat{\theta}; x) = \frac{\partial^2 \log L(\theta; x)}{\partial \theta^2} \Big|_{\theta=\hat{\theta}} < 0$$

o estimador de Máxima Verossimilhança é função de uma estatística suficiente

O teorema a seguir estabelece que o estimador de Máxima Verossimilhança é função de uma estatística suficiente.

Teorema: Sejam X_1, \dots, X_n uma amostra aleatória da variável aleatória X com função de densidade (ou de probabilidade) $f(x | \theta)$. Seja $T = T(X_1, \dots, X_n)$ uma estatística suficiente para θ . Então o estimador de máxima verossimilhança $\hat{\theta}$ (se existir) é função de T .

Princípio da Invariância

Teorema (O princípio da invariância): Seja $g(\cdot)$ uma função real 1:1 (inversível) definida em Θ . Sejam X_1, \dots, X_n uma amostra aleatória da variável aleatória X com função de densidade (ou de probabilidade) $f(x | \theta)$. Se $\hat{\theta}$ é um estimador de máxima verossimilhança de θ , então $g(\hat{\theta})$ é um estimador de máxima verossimilhança de $g(\theta)$.

Exemplos

Exemplo 1: Suponha X_1, \dots, X_n uma AAS de uma v.a. $X \sim N(\mu, \sigma^2)$, com σ^2 conhecido. Encontre o EMV de μ .

Exemplo 2: Sejam X_1, \dots, X_n a.a. da v.a. $X \sim N(\mu, \sigma^2)$. Aplique o princípio da invariância do EMV.

Resultados Assintóticos

Suponha agora que temos uma AAS de tamanho n , da v.a. X , ou seja, X_1, \dots, X_n , e que a distribuição de X envolve o parâmetro θ . Suponha ainda que X satisfaz as condições de regularidade exigidas no Teorema de Crámer-Rao, então, se $\hat{\theta}$ é o **estimador de Máxima Verossimilhança** de θ , temos que,

$$\sqrt{n}(\hat{\theta} - \theta) \xrightarrow{a} N\left(0, \frac{1}{I_F(\theta)}\right),$$

e

$$\sqrt{n}(g(\hat{\theta}) - g(\theta)) \xrightarrow{a} N\left(0, \frac{(g'(\theta))^2}{I_F(\theta)}\right)$$

em que " \xrightarrow{a} " significa **distribuição assintótica**.

Propriedades assintóticas do EMV

Para amostras grandes,

- Os estimadores de máxima verossimilhança de θ e $g(\theta)$ são **aproximadamente não viciados**,
- As variâncias coincidem com os correspondentes limites inferiores das variâncias dos estimadores não viciados de θ e $g(\theta)$. Portanto, temos que **o estimador de máxima verossimilhança é eficiente**.

EMV para o Caso multiparamétrico

- É possível generalizar os resultados da estimação por máxima verossimilhança para o caso multiparamétrico.
- Assim, pela distribuição de X envolve p parâmetros, $\theta = (\theta_1, \dots, \theta_p)$, então a função de verossimilhança associada a uma amostra aleatória, X_1, \dots, X_n é

$$L(\theta) = \prod_{i=1}^n f(x_i | \theta)$$

em que $p < n$.

Vetor Escore e Matriz de Informação de Fisher

- A função escore é substituída pelo **vetor escore** da v.a. X .

$$U(\theta_1, \dots, \theta_p) = \begin{bmatrix} \frac{\partial}{\partial \theta_1} \log f(x, \theta_1, \dots, \theta_p) \\ \vdots \\ \frac{\partial}{\partial \theta_p} \log f(x, \theta_1, \dots, \theta_p) \end{bmatrix}$$

- A informação de Fisher é substituída pela **matriz de informação de Fisher**:

$$K(\theta_1, \dots, \theta_p) = -\mathbb{E} \begin{bmatrix} \frac{\partial^2}{\partial \theta_1^2} \log f(x, \theta) & \cdots & \frac{\partial^2}{\partial \theta_1 \partial \theta_p} \log f(x, \theta) \\ \vdots & \ddots & \vdots \\ \frac{\partial^2}{\partial \theta_p \partial \theta_1} \log f(x, \theta) & \cdots & \frac{\partial^2}{\partial \theta_p^2} \log f(x, \theta) \end{bmatrix}$$

Propriedades Assintóticas do EMV caso multiparamétrico

Sob certas condições de regularidade vale o teorema da normalidade assintótica:

$$\sqrt{n}(\hat{\theta} - \theta) \xrightarrow{d} N_p \left(0, \frac{1}{K(\theta)} \right),$$

em que N_p denota a distribuição normal p variada e $\hat{\theta}$ obtido da **maximização da log-verossimilhança**, ou seja, equivalentemente, como solução do sistema

$$U(\theta_1, \dots, \theta_p) = \mathbf{0}$$

Verossimilhança para amostras independentes

- Suponha que temos **duas ou mais amostras independentes** de distribuições que dependem de um parâmetro, ou vetor de parâmetro.
- Por simplicidade, seja o caso de duas amostras independentes, ficando claro como estender para várias amostras independentes. Assim, sejam X_1, \dots, X_n e Y_1, \dots, Y_n duas amostras independentes, então,

$$L(\theta, x_1, \dots, x_n, y_1, \dots, y_n) = L(\theta, x_1, \dots, x_n)L(\theta, y_1, \dots, y_n)$$

em que $L(\theta, x_1, \dots, x_n)$ é a verossimilhança da amostra X_1, \dots, X_n e $L(\theta, y_1, \dots, y_n)$ é a verossimilhança da amostra Y_1, \dots, Y_n .

log-verossimilhança para amostras independentes

Daí, a log-verossimilhança é dada por

$$\ell(\boldsymbol{\theta}, x_1, \dots, x_n, y_1, \dots, y_n) = \ell(\boldsymbol{\theta}, x_1, \dots, x_n) + \ell(\boldsymbol{\theta}, y_1, \dots, y_n)$$

de tal forma que o logaritmo da verossimilhança conjunta é igual a **soma do logaritmo das verossimilhanças** correspondentes a cada uma das amostras.

Exemplo: Sejam X_1, \dots, X_n uma amostra aleatória correspondente a $X \sim N(\mu, 4)$ e Y_1, \dots, Y_n uma amostra aleatória correspondente a $Y \sim N(\mu, 9)$. Assumindo que as duas amostras são independentes.

Estimação pelo Método dos Momentos

Método dos momentos

- O método dos momentos é um dos métodos de estimação mais antigos e simples
- Suponha que X_1, \dots, X_n amostra aleatória de uma distribuição indexada por p parâmetros ($\theta_1, \dots, \theta_p$, $p < n$). Consideremos os p primeiros momentos da distribuição, $\mathbb{E}(X^k)$, $k = 1, \dots, n$.

Por exemplo, se a distribuição é contínua com densidade $f(x, \theta)$, então,

$$\mathbb{E}(X^k) = \int_{-\infty}^{\infty} x^k f(x, \theta) dx,$$

$\mathbb{E}(X), \dots, \mathbb{E}(X^p)$ são funções de parâmetros desconhecidos

$$\mathbb{E}(X^k) = M_k(\theta_1, \dots, \theta_p), \forall k = 1, \dots, p$$

Pela **Lei dos grandes números**, devemos esperar que $\frac{1}{n} \sum_{i=1}^n x_i^k$ seja próximo de $\mathbb{E}(X^k) = M_k$ se n é grande.

- O **método dos momentos** consiste em definir o seguinte conjunto de equações:

$$\left\{ \begin{array}{l} \frac{1}{n} \sum_{i=1}^n x_i = M_1(\theta_1, \dots, \theta_p) \\ \vdots \\ \frac{1}{n} \sum_{i=1}^n x_i^p = M_p(\theta_1, \dots, \theta_p) \end{array} \right.$$

e através da solução do sistema acima, encontrar estimadores para os parâmetros $\theta_1, \dots, \theta_p$, diga-se, $\hat{\theta}_1, \dots, \hat{\theta}_p$.

Exemplos

Exemplo: Suponha X_1, \dots, X_n uma amostra aleatória da distribuição $\Gamma(\alpha, \beta)$. Encontre o estimador de α e β pelo método dos momentos.